



Universidade Federal de Pernambuco

Centro de informática - CIn

Curso de Sistemas de Informação

**Signal: Tradução de Prediction Markets em Inteligência
Macroeconômica**

Trabalho de Conclusão de Curso de Graduação

por

Erick Daniel Alves de Lima

Orientador: Prof. José Carlos da Silva Cavalcanti

Recife

2026

Erick Daniel Alves de Lima

Signal: Tradução de Prediction Markets em Inteligência Macroeconômica

Monografia apresentada ao Curso de Sistemas de Informação do Centro de Informática da Universidade Federal de Pernambuco, como requisito parcial para obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. José Carlos da Silva Cavalcanti

Recife

2026

Erick Daniel Alves de Lima

Signal: Tradução de Prediction Markets em Inteligência Macroeconômica

Monografia apresentada ao Curso de Sistemas de Informação do Centro de Informática da Universidade Federal de Pernambuco, como requisito parcial para obtenção do título de Bacharel em Sistemas de Informação.

Aprovado em: _____ de _____ de _____.

Banca Examinadora

Prof. José Carlos da Silva Cavalcanti

Orientador

Universidade Federal de Pernambuco – UFPE

Prof. Dr. Vinícius Cardoso Garcia

Examinador

Universidade Federal de Pernambuco – UFPE

Recife

2026

Agradecimentos

À minha mãe, Daisy Gomes, por todo o amor, apoio e dedicação ao longo da minha vida. Sua força e incentivo foram fundamentais para que eu chegasse até aqui.

À minha noiva, Carla Rafaelly, pelo companheirismo, paciência e inspiração durante toda esta jornada.

Ao meu orientador, Professor José Carlos Silva Cavalcanti, pela orientação, confiança e valiosas contribuições para a realização deste trabalho.

Aos meus amigos Allyson Ryan, Jorge Freitas, Lucas Gabriel e Melk Victor, pela amizade, apoio e pelos momentos compartilhados ao longo dessa caminhada.

À minha família, pelo incentivo e por sempre acreditar em mim.

Por fim, agradeço a todos que, de alguma forma, contribuíram para minha formação acadêmica e para a conclusão deste trabalho.

Nenhuma grande coisa é criada de repente.

Epicteto

RESUMO

Este trabalho investiga a viabilidade de transformar sinais estatísticos extraídos de mercados preditivos em narrativas de inteligência macroeconômica em língua portuguesa. O problema de pesquisa consiste em verificar se modelos de linguagem podem converter variações probabilísticas desses mercados em explicações contextualizadas e factualmente ancoradas, tornando as informações mais acessíveis aos usuários. Para isso, foi desenvolvido o Signal, um sistema capaz de coletar dados da plataforma Polymarket, detectar automaticamente eventos relevantes por meio de um algoritmo baseado em z-score contextual e gerar narrativas utilizando modelos de linguagem de grande porte. A pesquisa adota o paradigma da Design Science Research, contemplando o desenvolvimento do artefato, a coleta e o processamento de séries temporais, a implementação do pipeline de detecção e geração textual e a avaliação dos resultados por meio do Brier Score e de uma rubrica qualitativa voltada à fidelidade factual, contextualização e controle de causalidade. Os resultados indicam que o sistema apresentou desempenho satisfatório, alcançando Brier Score de 0,142, pontuação média de 9,69 na avaliação qualitativa das narrativas e taxa de falsos positivos compatível com a meta estabelecida. Conclui-se que o Signal demonstra a viabilidade da integração entre mercados preditivos, detecção estatística e modelos de linguagem para produzir narrativas macroeconômicas automatizadas, contextualizadas e sustentadas pelos dados.

Palavras-chave: Mercados preditivos, Inteligência macroeconômica, Geração de linguagem natural, Detecção de anomalias, Design Science Research.

ABSTRACT

This study investigates the feasibility of transforming statistical signals extracted from prediction markets into macroeconomic intelligence narratives in Portuguese. The research problem consists of assessing whether large language models can convert probabilistic changes observed in prediction markets into contextualized and factually grounded explanations, making such information more accessible to users. To this end, Signal was developed, a system capable of collecting data from the Polymarket platform, automatically detecting relevant events through a contextual z-score-based algorithm, and generating narratives using large language models. The research adopts the Design Science Research paradigm, encompassing the development of the artifact, time-series data collection and processing, implementation of the detection and text generation pipeline, and evaluation through the Brier Score and a qualitative rubric focused on factual grounding, contextualization, and causality control. The results indicate that the system achieved satisfactory performance, obtaining a Brier Score of 0.142, an average qualitative evaluation score of 9.69, and a false-positive rate consistent with the predefined target. It is concluded that Signal demonstrates the feasibility of integrating prediction markets, statistical detection, and large language models to produce automated, contextualized, and data-driven macroeconomic narratives.

Keywords: Prediction markets, Macroeconomic intelligence, Natural language generation, Anomaly detection, Design Science Research.

LISTA DE FIGURAS

Figura 1	Arquitetura geral do sistema Signal.....	25
Figura 2	Tela inicial do sistema.	53
Figura 3	Gráficos de séries temporais e anomalias.	54
Figura 4	Métricas utilizadas para calibração do detector.	54

LISTA DE TABELAS

Tabela 1	Parâmetros de configuração utilizados no sistema Signal.....	26
Tabela 2	Escala relativa de magnitude dos sinais detectados.....	30
Tabela 3	Rubrica de avaliação qualitativa das narrativas geradas pelo Signal.....	34
Tabela 4	Notação utilizada nas formulações do detector.....	36
Tabela 5	Análise de sensibilidade do limiar z^* sobre o corpus de mercados coletados.	37
Tabela 6	Resultados da avaliação qualitativa por dimensão e lote	40
Tabela 7	Resumo do evento analisado	42
Tabela 8	Falsos positivos identificados durante a avaliação qualitativa.	45
Tabela 9	Síntese dos resultados obtidos na avaliação do sistema.	45

LISTA DE SIGLAS

API	Application Programming Interface
BS	Brier Score
CFTC	Commodity Futures Trading Commission
CLOB API	Central Limit Order Book API
COPOM	Comitê de Política Monetária
DSR	Design Science Research
FOMC	Federal Open Market Committee
LLM	Large Language Model
LMSR	Logarithmic Market Scoring Rule
NLG	Natural Language Generation
PIB	Produto Interno Bruto
pp	Pontos percentuais

SUMÁRIO

1	INTRODUÇÃO	12
1.1	Contexto e Motivação	12
1.2	O Sistema Signal	13
1.3	Pergunta de Pesquisa e Objetivos	14
1.4	Justificativa	15
1.5	Estrutura do Trabalho	16
2	REFERENCIAL TEÓRICO	17
2.1	O que são mercados preditivos?	17
2.2	Mercados preditivos aplicados à inteligência macroeconômica	18
2.3	Deteção de anomalias em séries temporais	19
2.4	Geração de linguagem natural baseada em dados	21
3	METODOLOGIA	24
3.1	Arquitetura geral do sistema	24
3.2	Implementação do sistema	26
3.3	Fonte de dados e critérios de seleção do corpus	27
3.4	Módulo de detecção: o z-score contextual	28
3.4.1	Pré-processamento	28
3.4.2	Formulação do z-score e escolha da janela	28
3.4.3	Critério de detecção e classificação de magnitude	29
3.4.4	Deduplicação por impacto ponderado	30
3.5	Módulo de Geração de Narrativas	30
3.5.1	Arquitetura de separação detecção-narrativa	30
3.5.2	Design do prompt e instrução de sistema	31
3.5.3	Cascata de modelos e fallback automático	31
3.6	Avaliação do artefato	32
3.6.1	Brier Score	32
3.6.2	Análise de sensibilidade do limiar z^*	33
3.6.3	Avaliação qualitativa das narrativas	33

3.6.4	Procedimento Experimental	34
3.7	Limitações Metodológicas	35
4	RESULTADOS	37
4.1	Análise de sensibilidade do limiar de detecção	37
4.2	Acurácia Preditiva: Brier Score	39
4.3	Avaliação qualitativa das narrativas	39
4.3.1	Resultados por lote e dimensão	39
4.3.2	Análise por dimensão	41
4.3.2.1	D1: Ancoragem Factual	41
4.3.2.2	D2: Integração do Tema	41
4.3.2.3	D3: Pertinência do Canal Brasil	41
4.3.2.4	D4: Controle de Causalidade	42
4.3.3	Exemplos representativos	42
4.4	Falsos positivos	44
4.5	Síntese dos resultados	45
5	CONCLUSÃO	47
	REFERÊNCIAS	50
	APÊNDICE A – Disponibilização e Guia do Artefato	52
5.1	Disponibilização do projeto	52
5.2	Organização do notebook	52
5.3	Interface do sistema	53
5.4	Arquivos produzidos	53
5.5	Reprodução dos experimentos	55

1 INTRODUÇÃO

1.1 Contexto e Motivação

Em 1907, o estatístico britânico Francis Galton analisou um concurso realizado em uma feira agrícola em Plymouth. Na ocasião, cerca de 800 participantes, incluindo fazendeiros, açougueiros e espectadores sem formação técnica específica, estimavam o peso de um boi após o abate. Galton, inicialmente cético em relação à capacidade de julgamento coletivo, esperava encontrar evidências da imprecisão das estimativas populares. O resultado, porém, contrariou sua expectativa: a mediana das estimativas foi de 1.207 libras, enquanto o peso real do animal era de 1.198 libras, o que representou um erro inferior a 1% [1]. Esse achado, publicado na *Nature* sob o título *Vox Populi*, tornou-se posteriormente um dos registros empíricos mais conhecidos do fenômeno que a literatura econômica contemporânea denomina agregação informacional. Em linhas gerais, esse conceito descreve a capacidade de sistemas descentralizados, compostos por agentes heterogêneos e relativamente independentes, produzirem estimativas coletivas mais precisas do que aquelas elaboradas por indivíduos isolados. A mesma intuição ganhou maior notoriedade fora da literatura econômica por meio da expressão *Wisdom of Crowds*, popularizada por James Surowiecki em *The Wisdom of Crowds* [2]. No cenário contemporâneo, os mercados preditivos passaram a representar uma das aplicações mais relevantes dessa propriedade. Nesses mercados, os participantes negociam contratos cujo valor depende da ocorrência de eventos futuros, como decisões de política monetária, indicadores macroeconômicos, resultados eleitorais ou eventos financeiros. O mecanismo central de cada contrato é simples: o comprador paga um preço entre zero e um dólar e recebe exatamente um dólar caso o evento especificado ocorra, e nada caso contrário. A consequência direta dessa estrutura é que o preço de mercado de cada contrato pode ser interpretado diretamente como a probabilidade que os participantes, coletivamente, atribuem à ocorrência do evento. Se um contrato sobre a manutenção da taxa de juros pelo Federal Reserve está sendo negociado a US\$ 0,72, por exemplo, isso indica que o mercado está precificando aproximadamente 72% de chance de que a taxa seja mantida. Essa aproximação entre preço e probabilidade implícita confere aos mercados preditivos parte relevante de seu conteúdo informativo. Diferentemente de pesquisas de opinião, esses mercados incorporam incentivos financeiros, pois previsões incorretas podem implicar perdas para os participantes.

Esse mecanismo tende a penalizar estimativas descuidadas e favorecer probabilidades mais calibradas. A relevância empírica desses instrumentos ganhou novo impulso em fevereiro de 2026, com a publicação de um working paper pelo Federal Reserve, banco central dos Estados Unidos. No estudo, Diercks, Katz e Wright analisam contratos da Kalshi, empresa de mercados preditivos regulada pela Commodity Futures Trading Commission (CFTC), relacionados a decisões do Federal Open Market Committee (FOMC) no período de 2022 a 2025. Os autores demonstram que as probabilidades implícitas nesses contratos apresentaram desempenho preditivo comparável e, em alguns casos, superior ao de instrumentos tradicionais e pesquisas de expectativas de analistas profissionais [3]. Paralelamente às evidências acadêmicas, os mercados preditivos passaram por um processo recente de institucionalização, com crescimento de plataformas como Kalshi e Polymarket, entrada de capital institucional e integração gradual a infraestruturas do mercado financeiro. Esse movimento sugere que tais mercados deixaram de ser apenas experimentos especulativos ou cripto-nativos e passaram a ocupar espaço na produção de sinais probabilísticos utilizados por investidores e instituições financeiras. A questão central deste trabalho reside na mediação entre o conteúdo informativo dos mercados preditivos e as formas pelas quais esse conteúdo pode ser interpretado e comunicado. Embora o preço de um contrato FOMC negociado a 72% possa ser lido por economistas, gestores de fundos ou analistas financeiros como uma probabilidade implícita, não é evidente que a simples disponibilidade desse número seja suficiente para produzir compreensão fora de contextos especializados. Uma probabilidade isolada não informa, por si só, se a variação observada é estatisticamente incomum, que mudança de expectativa ela representa ou quais impactos econômicos podem estar associados ao movimento. Assim, este trabalho investiga a viabilidade de transformar sinais estatísticos extraídos de mercados preditivos macroeconômicos em narrativas interpretáveis, contextualizadas e sustentadas pelos dados em língua portuguesa.

1.2 O Sistema Signal

O Signal é um sistema experimental de inteligência macroeconômica desenvolvido para operacionalizar a investigação proposta neste trabalho. Seu objetivo é avaliar se variações estatisticamente relevantes em séries de probabilidade de mercados preditivos podem ser identificadas automaticamente e convertidas em narrativas macroeconômicas

em língua portuguesa, mantendo aderência às informações de entrada. O sistema opera em três etapas principais. A primeira consiste na coleta de séries de probabilidade de contratos da Polymarket relacionados a eventos de relevância macroeconômica, com foco em decisões do Federal Reserve. A plataforma foi escolhida por disponibilizar dados públicos por meio de API e por operar contratos binários adequados ao objetivo experimental do trabalho. Na segunda etapa, o Signal aplica um detector estatístico para identificar deslocamentos incomuns nas probabilidades analisadas. Esses deslocamentos são tratados como sinais potenciais de mudança nas expectativas agregadas dos participantes do mercado. Na terceira etapa, os sinais detectados são convertidos em narrativas em português por modelos de linguagem de grande porte. Essas narrativas descrevem o fato observado, contextualizam o contrato monitorado e relacionam o movimento a possíveis canais de transmissão macroeconômica para o Brasil, como câmbio, juros domésticos, fluxo de capitais, custo de crédito e mercado acionário. A geração textual é organizada de modo que o modelo de linguagem não decida autonomamente quando há um evento relevante. Essa decisão permanece sob responsabilidade do detector estatístico. O modelo recebe informações previamente calculadas, o que busca reduzir o risco de inferências não sustentadas pelos dados fornecidos. Assim, o Signal não é apresentado como um produto final validado comercialmente, mas como um protótipo funcional destinado a avaliar, de forma controlada, a viabilidade técnica da conversão de sinais de mercados preditivos em explicações macroeconômicas em linguagem natural.

1.3 Pergunta de Pesquisa e Objetivos

O trabalho é orientado pela seguinte pergunta de pesquisa: “Em que medida modelos de linguagem natural são capazes de transformar sinais estatísticos extraídos de mercados preditivos em narrativas macroeconômicas factualmente ancoradas?” O objetivo geral é investigar se um sistema computacional é capaz de detectar automaticamente sinais estatísticos em mercados preditivos macroeconômicos e convertê-los em narrativas factualmente ancoradas em língua portuguesa. Os objetivos específicos são: (i) coletar e processar séries temporais de probabilidade de contratos da Polymarket relacionados a eventos macroeconômicos, com foco em decisões do Federal Reserve; (ii) implementar e parametrizar um detector de anomalias baseado em z-score com janela deslizante; (iii) analisar sensibilidade dos limiares de detecção, avaliando como diferentes parâmetros afe-

tam a quantidade e a qualidade dos sinais identificados; (iv) desenvolver um pipeline de geração automática de narrativas em língua portuguesa a partir dos sinais estatísticos detectados; (v) avaliar qualitativamente o grau de ancoragem factual das narrativas geradas em relação às informações de entrada; e (vi) documentar o ciclo iterativo de avaliação e refinamento do sistema como evidência do processo metodológico adotado.

1.4 Justificativa

A justificativa deste trabalho parte da crescente relevância dos mercados preditivos como fonte de expectativas macroeconômicas em alta frequência. Diferentemente de pesquisas periódicas com analistas ou instrumentos tradicionais de mercado, esses contratos produzem séries de probabilidade atualizadas continuamente à medida que novas informações são incorporadas pelos participantes. Assim, seu valor não está apenas na probabilidade observada em determinado momento, mas também na trajetória de suas variações ao longo do tempo. Essa característica torna o monitoramento contínuo particularmente relevante. Uma consulta pontual indica apenas qual probabilidade o mercado atribui a determinado evento, enquanto o acompanhamento da série permite observar quando essa probabilidade mudou, em qual direção e com que intensidade. Em eventos macroeconômicos sensíveis, como decisões do Federal Reserve, essas mudanças podem refletir revisões relevantes nas expectativas dos participantes diante de novos dados de inflação, emprego, atividade econômica ou comunicação de autoridades monetárias. Entretanto, a interpretação dessas variações depende do comportamento histórico de cada contrato. Um deslocamento de três pontos percentuais pode representar apenas uma oscilação rotineira em mercados naturalmente voláteis, enquanto o mesmo movimento pode indicar uma alteração significativa em contratos que apresentam baixa variabilidade. Dessa forma, a identificação de eventos relevantes requer métodos capazes de contextualizar cada observação em relação ao histórico recente da própria série temporal. No contexto brasileiro, a relevância do tema ganhou contornos adicionais com o anúncio, em março de 2026, de uma parceria entre a XP International e a Kalshi para disponibilizar mercados preditivos a investidores brasileiros por meio de uma plataforma offshore. Embora o ambiente regulatório nacional imponha restrições a determinados tipos de contratos, a chegada formal dessa categoria de ativo ao público brasileiro reforça a pertinência de investigar ferramentas capazes de interpretar seus sinais, sobretudo quando associa-

dos a eventos macroeconômicos e financeiros. Ademais, apesar da crescente utilização de mercados preditivos para monitoramento econômico, ainda existem poucos estudos que investigam como seus sinais podem ser comunicados automaticamente em linguagem natural de forma factual, contextualizada e interpretável. Dessa forma, este trabalho busca contribuir tanto para a literatura sobre mercados preditivos quanto para a investigação do uso de modelos de linguagem natural em domínios especializados, avaliando a viabilidade de transformar sinais quantitativos em narrativas macroeconômicas factualmente ancoradas.

1.5 Estrutura do Trabalho

Além desta introdução, o trabalho está organizado em quatro capítulos. A Seção 2 desenvolve o referencial teórico, abordando a agregação informacional, a emergência dos mercados preditivos, o uso desses mercados como fonte de expectativas macroeconômicas em alta frequência, métodos de detecção de anomalias em séries temporais financeiras e os fundamentos da geração de linguagem natural em domínios econômicos. A Seção 3 descreve a metodologia adotada, incluindo a fonte de dados, os critérios de seleção dos contratos analisados, o pipeline de detecção estatística, o pipeline de geração textual e os protocolos de avaliação qualitativa. A Seção 4 apresenta os resultados obtidos, com destaque para a análise de sensibilidade dos limiares de detecção, a avaliação factual das narrativas geradas, a aplicação da rubrica qualitativa e a análise dos falsos positivos. Por fim, a Seção 5 reúne as conclusões, as principais contribuições do trabalho, suas limitações e possibilidades de pesquisa futura.

2 REFERENCIAL TEÓRICO

A organização deste capítulo segue uma progressão lógica que parte da fundamentação econômica dos mercados preditivos, avança para sua aplicação na inteligência macroeconômica e culmina nos fundamentos computacionais necessários para a detecção de eventos relevantes e sua transformação em narrativas automatizadas. Essa sequência acompanha a própria lógica operacional do Signal: da fonte de dados à narrativa final.

2.1 O que são mercados preditivos?

Mercados preditivos são plataformas em que contratos financeiros são negociados com base na probabilidade de ocorrência de eventos futuros. O preço de cada contrato corresponde diretamente à crença coletiva dos participantes sobre o evento: um contrato que paga US\$ 1 caso o Federal Reserve corte os juros, negociado a US\$ 0,72, expressa que o mercado atribui 72% de probabilidade a esse desfecho. Wolfers e Zitzewitz mostram que mercados preditivos, quando suficientemente líquidos e bem desenhados, podem agregar informação dispersa e produzir previsões competitivas em relação a benchmarks tradicionais [4]. Os próprios autores ressaltam, contudo, que essa capacidade depende criticamente do desenho do mercado e do volume negociado: contratos com liquidez insuficiente produzem preços facilmente distorcidos por poucos participantes, ressalva que antecipa uma limitação prática que o presente trabalho precisa endereçar já na etapa de coleta de dados. A razão teórica pela qual o preço de mercado consegue agregar informação dispersa de forma eficiente foi estabelecida por Hayek: o sistema de preços transmite conhecimento disperso entre agentes de forma mais eficiente do que qualquer mecanismo de coleta centralizada [5]. Enquanto Hayek oferece a explicação teórica para essa dispersão, Galton fornece sua primeira evidência empírica: a mediana das estimativas de 800 participantes para o peso de um boi (pessoas sem qualquer formação técnica) errou por menos de 1% em relação ao valor real [1]. Essa propriedade foi posteriormente formalizada por Fama como Hipótese dos Mercados Eficientes, segundo a qual mercados competitivos incorporam informação nova nos preços de forma rápida, ainda que não instantânea. Como a incorporação da informação ocorre rapidamente, mas não de forma instantânea, torna-se possível detectar movimentos informacionalmente relevantes antes que o mercado atinja um novo equilíbrio [6]. A viabilidade prática desses mercados depende, ainda, de um

mecanismo que garanta liquidez mesmo na ausência de contrapartes imediatas. Hanson resolveu esse problema com o Logarithmic Market Scoring Rule (LMSR), mecanismo de formação de preço que assegura ser sempre possível negociar um contrato e que se tornou padrão nas plataformas de mercados preditivos [7]. Esse mecanismo, validado pelo Iowa Electronic Market (1988) e consolidado por plataformas como a Intrade (1999-2013), sustenta o funcionamento de plataformas contemporâneas como a Polymarket (fonte de dados do presente trabalho), escolhida por disponibilizar histórico de preços via API pública, sem custos de licenciamento ou exigência de credenciais. Uma vez estabelecidas essas propriedades, torna-se possível compreender por que tais mercados passaram a ser utilizados como instrumentos auxiliares de monitoramento macroeconômico, tema discutido na seção seguinte.

2.2 Mercados preditivos aplicados à inteligência macroeconômica

Uma vez estabelecido que mercados preditivos sintetizam expectativas coletivas de forma eficiente, passa a ser necessário compreender como essa síntese pode ser utilizada para monitorar a conjuntura econômica antes da divulgação de dados oficiais. Essa aplicação situa-se no campo do nowcasting, onde a estimativa do estado corrente de variáveis econômicas cujos dados oficiais são divulgados com defasagem [8]. O Produto Interno Bruto (PIB), por exemplo, é divulgado com defasagem de 30 a 90 dias; indicadores de mercado de trabalho, com cerca de 30 dias. Sob essa perspectiva, mercados preditivos oferecem uma vantagem que modelos de fatores tradicionais não possuem: em vez de inferir o estado da economia a partir de correlações históricas, produzem diretamente estimativas probabilísticas sobre variáveis de política monetária, que são o objeto de interesse imediato de analistas e formuladores de política. Kuttner e Piazzesi e Swanson estabeleceram que contratos de mercado antecipam surpresas de política monetária com precisão superior à de modelos estruturais tradicionais [9] [10]. Vale notar, entretanto, que os próprios autores reconhecem uma limitação metodológica relevante: contratos futuros de juros incorporam não apenas a expectativa de mercado sobre o evento, mas também um prêmio de risco que pode distorcer a leitura da probabilidade implícita em horizontes mais longos. Essa ressalva reforça a opção do presente trabalho por detectar variações relativas ao comportamento recente de cada contrato, e não por interpretar o nível absoluto da probabilidade como medida pura de expectativa. Essa linha de evidência foi

recentemente reforçada por um working paper publicado pelo Federal Reserve, no qual se documenta que as probabilidades implícitas em contratos da Kalshi para decisões do Federal Open Market Committee (FOMC), no período de 2022 a 2025, apresentaram Brier Score inferior ao de modelos econométricos tradicionais e ao Survey of Professional Forecasters [3]. Essa métrica avalia a acurácia de previsões probabilísticas ao medir a distância entre a probabilidade estimada e o resultado observado, de modo que valores menores indiquem previsões mais precisas. Esse resultado reforça a pertinência de utilizar séries de probabilidade de mercados preditivos como fonte de inteligência macroeconômica, embora diferenças entre plataformas, regimes regulatórios e liquidez recomendem cautela na generalização direta para a Polymarket. Entretanto, embora esses mercados forneçam informações valiosas, sua interpretação exige metodologias capazes de distinguir alterações informacionais relevantes das oscilações normais do processo de negociação. A literatura de nowcasting fornece, assim, a base conceitual para o monitoramento automático desenvolvido neste trabalho - mas, para que essas probabilidades sejam de fato utilizáveis operacionalmente, exige-se um mecanismo formal capaz de identificar automaticamente quando seu comportamento se desvia do padrão recente.

2.3 Detecção de anomalias em séries temporais

A operacionalização do valor informacional dos mercados preditivos pelo Signal requer um mecanismo capaz de distinguir, de forma automática, variações de sinal genuíno do ruído estocástico presente em qualquer série temporal financeira. Chandola, Banerjee e Kumar e, mais recentemente, Blázquez-García et al. sistematizam a taxonomia de métodos de detecção de anomalias em três categorias: de ponto, contextuais e coletivas. O detector implementado no Signal pertence à categoria de anomalias contextuais, sendo observações anômalas em relação ao comportamento local imediato da série, não necessariamente ao comportamento histórico global [11] [12]. Essa escolha é adequada porque séries de probabilidade de mercados preditivos são intrinsecamente heterocedásticas, o que significa que a volatilidade de um contrato varia ao longo de seu ciclo de vida, sendo maior próximo à data do evento e menor em períodos distantes. O z-score com janela deslizante de 14 dias adapta-se a essa heterocedasticidade ao estimar o desvio-padrão localmente, sem impor estrutura paramétrica sobre a volatilidade global da série, uma propriedade documentada por Iglewicz e Hoaglin para detectores de outliers em séries

com distribuições moderadamente assimétricas [13]. Para os objetivos deste trabalho, a principal vantagem do z-score sobre métodos mais sofisticados é a interpretabilidade direta: a afirmação de que uma variação é "cerca de quatro vezes maior do que o padrão histórico recente deste contrato" é diretamente traduzível em linguagem natural, sem etapas adicionais de explicação, sendo uma propriedade essencial para um sistema cuja saída final é uma narrativa textual. Essa escolha em relação a alternativas mais sofisticadas merece justificativa explícita. Métodos baseados em amplitude interquartil (IQR) são mais robustos a outliers extremos, mas exigem janelas maiores para estimação estável, o que reduziria a sensibilidade do detector a eventos recentes. Modelos não supervisionados, como Isolation Forest e Local Outlier Factor (LOF), capturam padrões multivariados complexos. Entretanto, demandam volume de dados de treinamento incompatível com séries de contratos individuais, frequentemente compostas por poucas dezenas de observações. Modelos de decomposição como Prophet e abordagens baseadas em resíduos de ARIMA, por sua vez, assumem sazonalidade ou estrutura autorregressiva que não se verifica em séries de probabilidade de eventos únicos, como uma reunião específica do FOMC. De forma mais ampla, embora métodos baseados em aprendizado profundo apresentem desempenho superior em determinados cenários de previsão, eles demandam grandes volumes de dados de treinamento e reduzem significativamente a interpretabilidade do processo decisório - característica incompatível com o objetivo deste trabalho, que depende da tradução direta de cada sinal em linguagem natural. A parametrização do detector - janela de 14 dias, limiar $z^* = 2,0$ e filtro de variação absoluta mínima de 3 pontos percentuais - foi determinada por análise de sensibilidade sistemática com os thresholds $z^* = 1,5; 2,0; 2,5$, reportada na Seção 4. Os parâmetros foram definidos considerando o equilíbrio entre sensibilidade e estabilidade do detector, buscando minimizar tanto falsos positivos quanto a perda de eventos relevantes. O filtro de variação mínima complementa o z-score ao eliminar casos em que uma variação numericamente pequena, em um contrato de volatilidade historicamente muito baixa, gera z-score elevado sem relevância informacional real. Essa precaução é particularmente relevante porque, como apontado na literatura de mercados preditivos, contratos pouco negociados tendem a produzir sinais mais ruidosos - o preço reage de forma desproporcional a transações isoladas, na ausência de massa crítica de participantes. A razão de cobertura líquida - proporção de sinais detectados em contratos com volume superior a US\$ 1 milhão - permanece estável em 0,95 nos três limiares ava-

liados, evidenciando robustez do parâmetro adotado mesmo diante desse risco de ruído. A detecção de anomalias torna-se, assim, a etapa responsável por transformar uma série temporal contínua em um conjunto discreto de eventos semanticamente relevantes - restando, então, o desafio de comunicar esses eventos de maneira compreensível ao usuário final.

2.4 Geração de linguagem natural baseada em dados

Após a identificação de um sinal estatístico, ainda resta uma etapa essencial: transformar esse dado em uma explicação compreensível para o usuário final. No caso do Signal, essa etapa se aproxima do campo conhecido como Natural Language Generation (NLG), ou geração automática de linguagem natural a partir de dados estruturados. Seu propósito é converter informações numéricas, como variações de probabilidade, direção do movimento e intensidade estatística, em uma narrativa capaz de explicar o que aconteceu e por que aquele sinal pode ser relevante no contexto econômico analisado. A geração de linguagem natural não é um campo recente. McKeown já investigava formas de produzir textos a partir de bases estruturadas de informação, enquanto Reiter e Dale consolidaram uma arquitetura modular que separa o processo de geração em etapas, como seleção do conteúdo, organização do texto e realização linguística. Essa abordagem marcou a área por oferecer maior controle sobre a saída produzida, especialmente em sistemas baseados em regras, nos quais cada etapa do texto podia ser planejada de maneira mais previsível [14] [15]. Com o avanço das técnicas estatísticas e, mais recentemente, dos modelos neurais de larga escala, a geração automática de texto passou a alcançar níveis muito superiores de fluidez. Gatt e Krahmer descrevem essa evolução como uma transição de sistemas mais rígidos, baseados em regras, para arquiteturas capazes de aprender padrões linguísticos de forma mais flexível. Esse avanço ampliou a capacidade expressiva dos sistemas de NLG, mas também trouxe um problema relevante: quanto maior a liberdade do modelo para gerar texto, maior tende a ser o risco de produzir afirmações não sustentadas pelos dados fornecidos [16]. Esse risco aparece com especial força nos modelos de linguagem de grande porte, ou LLMs. Ji et al. [17] mostram que esses modelos podem gerar textos bem escritos e convincentes, mas nem sempre fiéis às informações de entrada. Esse fenômeno, conhecido como alucinação, ocorre quando o modelo inclui dados incorretos, inferências não verificadas ou explicações que não estão amparadas pelas evidências

disponíveis. Em um domínio como o macroeconômico, esse problema é particularmente sensível, pois uma frase aparentemente plausível pode levar o leitor a interpretar de maneira equivocada uma mudança nas expectativas de mercado. A arquitetura do Signal foi desenhada justamente para reduzir esse risco. O sistema separa a etapa de detecção estatística da etapa de geração textual. Essa decisão encontra respaldo em Liu et al. [18], que propõem, no sistema TS-Agent, uma separação entre a extração de evidências em séries temporais e a interpretação dessas evidências por modelos de linguagem. Embora esse tipo de abordagem ainda tenha sido avaliado principalmente em ambientes controlados, o princípio é relevante para este trabalho: o modelo de linguagem não deve decidir sozinho o que é estatisticamente importante. No Signal, essa separação funciona de maneira direta. O modelo de linguagem não recebe a série temporal bruta, nem precisa identificar por conta própria se houve um evento relevante. Essa decisão já foi tomada antes, pelo detector estatístico. O modelo recebe apenas um conjunto de informações estruturadas, como a data do sinal, a direção da variação, a mudança em pontos percentuais e a intensidade estatística do movimento. A partir desses elementos, sua função é produzir uma explicação em português que seja clara, contextualizada e fiel aos dados de entrada. Essa distinção é central para o trabalho. O modelo de linguagem não cria conhecimento novo sobre o evento monitorado. Ele apenas transforma em texto informações que já foram identificadas e quantificadas pelo pipeline estatístico. A definição de quando o sinal ocorreu, qual foi sua direção e qual sua magnitude permanece sob responsabilidade do detector. Ao LLM cabe a tarefa de organizar essas informações em uma narrativa compreensível, preservando a aderência factual. Do ponto de vista da arquitetura do sistema, essa lógica se traduz em um pipeline com módulos bem definidos. Primeiro, os dados são coletados da Polymarket. Em seguida, o detector estatístico identifica variações incomuns nas probabilidades dos contratos. Depois, o modelo de linguagem recebe os campos estruturados e gera a narrativa final. Essa divisão favorece a rastreabilidade, pois cada afirmação presente no texto gerado pode ser relacionada a uma informação previamente calculada pelo sistema. A avaliação das narrativas também precisa considerar essa preocupação com fidelidade factual. Métricas automáticas como BLEU, ROUGE e BERTScore são úteis para comparar textos com referências previamente definidas, mas não verificam, por si só, se uma probabilidade foi citada corretamente, se a direção do movimento foi descrita sem erro ou se o impacto econômico foi contextualizado de forma adequada. Por esse

motivo, este trabalho utiliza uma rubrica qualitativa, detalhada na Seção 3, composta por quatro dimensões: ancoragem factual, integração do tema, impacto contextualizado para o Brasil e controle de causalidade. Essa rubrica atua como uma camada complementar de validação. A separação entre detector estatístico e modelo de linguagem reduz o risco de alucinação desde a origem, pois limita o espaço de decisão do LLM. A avaliação qualitativa, por sua vez, verifica se essa estratégia foi efetiva nas narrativas produzidas. Assim, o Signal combina rastreabilidade técnica e controle textual, buscando assegurar que a fluidez da narrativa não comprometa a precisão das informações comunicadas.

Em conjunto, os fundamentos apresentados neste capítulo estabelecem a base conceitual necessária para o desenvolvimento da arquitetura proposta neste trabalho. A literatura revisada justifica tanto a utilização dos mercados preditivos como fonte de inteligência econômica quanto a adoção de métodos estatísticos para identificação de eventos relevantes e de técnicas de geração de linguagem natural para comunicação automatizada desses resultados. Embora cada um desses três eixos seja amplamente estudado de forma independente, poucos trabalhos exploram sua integração em um fluxo único, capaz de monitorar mercados preditivos macroeconômicos e traduzir automaticamente suas variações relevantes em análises textuais contextualizadas para o público brasileiro. A partir dessa fundamentação, o capítulo seguinte descreve os procedimentos metodológicos empregados na construção do sistema. Os conceitos apresentados neste capítulo não são empregados de forma isolada, mas articulados na arquitetura proposta, em que cada componente operacional possui respaldo na literatura correspondente.

3 METODOLOGIA

O presente trabalho adota o paradigma da Design Science Research (DSR), modalidade metodológica consolidada em Sistemas de Informação para pesquisas cujo resultado primário é um artefato computacional [19]. Nessa perspectiva, o sistema Signal constitui simultaneamente o produto da pesquisa e o veículo de investigação da questão de pesquisa sobre o valor informacional dos mercados preditivos: suas propriedades técnicas, o desempenho do artefato na identificação e interpretação dos sinais estatísticos e a qualidade das narrativas geradas constituem as evidências centrais a partir das quais a questão de pesquisa é respondida. A abordagem DSR avalia o artefato por critérios de utilidade, rigor e novidade em relação ao estado da arte, e não exclusivamente por critérios de verdade proposicional [20]. A metodologia organiza-se em quatro etapas sequenciais: revisão da literatura e fundamentação teórica, detalhada no Capítulo 2; coleta e pré-processamento dos dados de probabilidade; construção e parametrização do pipeline de detecção, geração e avaliação; e avaliação do artefato por critérios qualitativos. As etapas 2 a 4 são descritas nas seções seguintes.

3.1 Arquitetura geral do sistema

O Signal é estruturado como um pipeline sequencial de cinco módulos, cada um com responsabilidade funcional delimitada: (1) Coleta, responsável pela aquisição e limpeza dos dados brutos da Polymarket; (2) Detecção, que aplica o z-score contextual sobre as séries de probabilidade; (3) Deduplicação, que seleciona um único sinal representativo por evento e por janela temporal; (4) Geração, que produz narrativas em linguagem natural por meio de modelos de linguagem; e (5) Avaliação, que organiza os dados necessários à análise das narrativas, apoia a aplicação da rubrica qualitativa e calcula o Brier Score sobre contratos com desfecho conhecido. A Figura 1 apresenta a arquitetura geral do sistema.

Para ilustrar o percurso de um contrato no sistema: após a coleta, calcula-se a série de variações diárias; aplica-se o detector de z-score contextual; os sinais aprovados passam pelo módulo de deduplicação; os sinais selecionados são convertidos em dados estruturados enviados ao modelo de linguagem; as narrativas geradas são armazenadas no feed e submetidas à avaliação qualitativa. Esse ciclo completo é executado de forma automática




Figura 1: Arquitetura geral do sistema Signal.

e idempotente a cada execução do pipeline. A separação em módulos com interfaces bem definidas serve a dois propósitos distintos. No plano técnico, permite substituir qualquer módulo - por exemplo, trocar o detector por um algoritmo de changepoint sem alterar o restante do pipeline. No plano metodológico, garante rastreabilidade: cada decisão de design é localizada em um módulo específico e pode ser avaliada de forma independente, requisito do paradigma DSR [19]. A Tabela 1 consolida os parâmetros de configuração do sistema, centralizando em um único ponto de referência os valores que serão mencionados ao longo das seções seguintes.

Tabela 1: Parâmetros de configuração utilizados no sistema Signal.

Parâmetro	Valor	Módulo de referência
Janela do z-score	14 dias	Detecção
Limiar z^* (padrão)	2,0	Detecção
Filtro de variação absoluta mínima	3,0 pp	Detecção
Piso de volatilidade local	1,0 pp	Detecção
Janela de deduplicação	7 dias	Deduplicação
Volume mínimo — contratos encerrados	US\$ 500k	Coleta
Volume mínimo — contratos ativos	US\$ 50k	Coleta
Volume proxy de qualidade	US\$ 1M	Avaliação

3.2 Implementação do sistema

O Signal é implementado em Python 3.10, com bibliotecas voltadas à comunicação com APIs, manipulação de dados e integração com modelos de linguagem. A biblioteca requests é utilizada nas chamadas às APIs da Polymarket e aos provedores de LLMs, enquanto pandas e numpy apoiam o tratamento das séries temporais e o cálculo do z-score. Quando necessário, o sistema recorre a bibliotecas específicas de integração, como google-genai para chamadas ao Gemini 2.5 Flash. A geração textual é realizada por uma cascata de modelos, composta por Gemini 2.5 Flash, Llama 3.3 70B, Gemma 3 12B e Qwen 2.5 72B. Os resultados são persistidos em `demo_cache.json` e consumidos pelo dashboard HTML estático no navegador, sem necessidade de servidor intermediário. Os parâmetros do sistema estão centralizados em um único dicionário de configuração (PARAMS), reproduzindo integralmente os experimentos mediante a mesma versão do código e dos dados coletados - propriedade de reprodutibilidade requerida pelo paradigma DSR [19]. Do ponto de vista de complexidade computacional, o pipeline executa processamento linear

em relação ao número de contratos, com o tempo de execução dominado pelas chamadas às APIs externas. O código-fonte será disponibilizado juntamente com a versão final do trabalho.

3.3 Fonte de dados e critérios de seleção do corpus

Os dados primários são obtidos por meio de duas APIs públicas da Polymarket. A Gamma API fornece metadados dos eventos - título, volume financeiro e resultado final quando disponível. A CLOB API (Central Limit Order Book) fornece o histórico de preços diários de cada contrato, expresso na escala $[0, 1]$ e interpretado diretamente como probabilidade implícita de mercado, conforme demonstrado por Wolfers e Zitzewitz [4]. As probabilidades implícitas são convertidas para escala percentual $[0, 100]$ ao longo de todo o pipeline. A seleção dos contratos segue dois critérios de inclusão: (i) volume total negociado superior aos limiares definidos na Tabela 1 - justificados economicamente pelo fato de que contratos de baixa liquidez são mais suscetíveis a oscilações causadas por poucos participantes, comprometendo a leitura do preço como consenso de mercado genuíno; e (ii) disponibilidade de histórico mínimo de sete observações, necessário para o cálculo estável do z-score na janela inicial. Os contratos são organizados em cinco categorias temáticas cobertas pelos termos de busca do sistema: FOMC, Inflação, Crescimento, Cripto e Comércio. O período de coleta - janeiro de 2024 a junho de 2026 - foi escolhido por contemplar a consolidação da Polymarket como plataforma de referência para mercados macroeconômicos e por abranger múltiplos ciclos completos de reuniões do FOMC, condição necessária para observar o comportamento do detector em diferentes regimes de política monetária. Aplicados os critérios de inclusão a esse período, o corpus resultante compreende 51 contratos, 22 da categoria FOMC e 29 de Cripto. A concentração nessas duas categorias decorre da ausência de contratos com volume e histórico suficientes nas demais categorias na Polymarket durante o período avaliado - limitação discutida na Seção 3.7. Dos 51 contratos, 37 possuem desfecho conhecido, compondo o subconjunto sobre o qual o Brier Score é calculado.

3.4 Módulo de detecção: o z-score contextual

3.4.1 Pré-processamento

Em que $P(t)$ representa a probabilidade negociada pelo contrato no instante t , $P(t-1)$ representa a probabilidade observada no período imediatamente anterior e $\Delta P(t)$ corresponde à variação absoluta da probabilidade entre duas observações consecutivas, expressa em pontos percentuais.

$$\Delta P(t) = P(t) - P(t-1) \quad (3.1)$$

O detector opera sobre essa série de primeira diferença porque o objeto de interesse é a velocidade de mudança das probabilidades, e não seus níveis absolutos. Além disso, o uso da primeira diferença reduz os efeitos de tendência presentes no nível da série, que poderiam introduzir não estacionariedade adicional e comprometer a estimação da volatilidade local. A volatilidade local é estimada pelo desvio-padrão amostral das variações observadas nos 14 dias imediatamente anteriores a cada observação, sendo exigidas no mínimo cinco observações para que essa estimação seja considerada estável.

3.4.2 Formulação do z-score e escolha da janela

A formulação implementada é apresentada na Equação 3.2.

$$z(t) = \frac{\Delta P(t)}{\hat{\sigma}(t)} \quad (3.2)$$

Em que $z(t)$ representa o z-score contextual da observação no instante t , $\Delta P(t)$ corresponde à variação diária da probabilidade definida na Equação 3.1 e $\hat{\sigma}(t)$ representa o desvio-padrão amostral das variações diárias observadas nos 14 dias anteriores.

Na implementação do sistema, $\hat{\sigma}(t)$ possui um piso de 1,0 ponto percentual, adotado para evitar instabilidades numéricas decorrentes de volatilidade muito baixa. A formulação não subtrai a média das variações, opção justificada pelo fato de que, em janelas curtas, as primeiras diferenças de séries de probabilidade apresentam média próxima de zero, tornando essa subtração numericamente pouco relevante, ao mesmo tempo em que introduziria variabilidade adicional na estimação. Essa padronização por volatilidade local é análoga à amplamente utilizada na literatura de detecção de anomalias em séries

financeiras [11].

A janela de 14 dias representa aproximadamente um terço do intervalo médio entre reuniões do FOMC, de 45 dias. Essa proporção permite estimar a volatilidade do regime corrente sem incorporar integralmente ciclos anteriores, cujas condições de mercado podem diferir substancialmente. Janelas mais curtas resultariam em estimativas instáveis do desvio-padrão; janelas mais longas tenderiam a suavizar excessivamente a heterocedasticidade inerente aos contratos preditivos, reduzindo a sensibilidade do detector nos períodos de alta volatilidade próximos às datas de decisão. Os valores adotados foram inicialmente definidos com base na literatura de detecção de anomalias em séries financeiras e posteriormente refinados durante o desenvolvimento iterativo do artefato, em conformidade com o paradigma DSR adotado.

3.4.3 Critério de detecção e classificação de magnitude

Uma observação é classificada como sinal candidato quando satisfaz simultaneamente os critérios apresentados nas Equações 3.3 e 3.4.

$$|z(t)| \geq z^* = 2,0 \quad (3.3)$$

$$|\Delta P(t)| \geq 3,0 \text{ pp} \quad (3.4)$$

Nas Equações 3.3 e 3.4, $z(t)$ representa o z-score contextual calculado para a observação, z^* corresponde ao limiar mínimo adotado pelo detector para caracterizar uma anomalia estatística e $\Delta P(t)$ representa a variação absoluta diária da probabilidade, expressa em pontos percentuais.

O critério dual é necessário porque, em contratos com volatilidade histórica muito baixa, variações absolutas pequenas e financeiramente irrelevantes podem produzir z-scores elevados. O piso de 3,0 pp elimina esses falsos alarmes sem sacrificar a cobertura de eventos genuínos.

Os sinais detectados são classificados em quatro categorias de magnitude por escala relativa ao limiar z^* , conforme apresentado na Tabela 2. A escala relativa garante que a distribuição de magnitudes seja preservada ao variar z^* na análise de sensibilidade - propriedade que uma escala de limiares absolutos não assegura.

Tabela 2: Escala relativa de magnitude dos sinais detectados.

Categoria	Faixa de z (com $z^* = 2,0$)	Interpretação
Moderado	$2,0 \leq z < 3,0$	Incomum, mas dentro de faixas observadas
Significativo	$3,0 \leq z < 4,0$	Raro: ocorre em menos de 5% das observações sob normalidade
Forte	$4,0 \leq z < 5,0$	Muito raro: típico de choques informativos relevantes
Raro	$ z \geq 5,0$	Evento estatisticamente extremo

3.4.4 Deduplicação por impacto ponderado

O detector pode produzir múltiplos sinais em contratos distintos pertencentes ao mesmo evento pai da Polymarket. Por exemplo, um corte de 25 bps e um corte de 50 bps para a reunião de setembro de 2025 correspondem a contratos distintos, mas representam o mesmo evento macroeconômico. A deduplicação opera em dois estágios: agrupamento por título do evento pai e seleção de um único sinal por janela de sete dias dentro de cada grupo, priorizando o sinal de maior impacto, definido pela Equação 3.5.

$$\text{Impacto}(t) = |z(t)| \times \log(1 + \text{Volume}) \quad (3.5)$$

Em que $\text{Impacto}(t)$ representa a pontuação utilizada para priorização dos sinais durante a deduplicação, $z(t)$ corresponde ao z-score contextual da observação e Volume representa o volume financeiro acumulado negociado pelo contrato, expresso em dólares norte-americanos.

Essa métrica combina a intensidade estatística do movimento com a liquidez do contrato, penalizando contratos com baixo volume negociado e favorecendo aqueles cujo sinal possui maior relevância informacional.

3.5 Módulo de Geração de Narrativas

3.5.1 Arquitetura de separação detecção-narrativa

O sistema adota a separação entre detecção estatística e geração de linguagem natural, paradigma recomendado por Liu et al. [18] para sistemas de análise de séries temporais baseados em LLMs. O modelo de linguagem nunca recebe a série temporal bruta como entrada; recebe exclusivamente os campos estruturados produzidos pelo detector: data do sinal, probabilidades antes e depois, variação em pontos percentuais, intensidade relativa, direção, magnitude classificada, volume e resultado final quando dis-

ponível. Essa separação cumpre três funções: impede que o modelo utilize conhecimento memorizado para construir a narrativa em lugar dos dados fornecidos; garante reprodutibilidade, pois os mesmos dados produzem narrativas comparáveis independentemente do modelo ativado; e viabiliza a avaliação quantitativa da ancoragem factual, pois os campos que devem aparecer na narrativa são conhecidos a priori.

3.5.2 Design do prompt e instrução de sistema

A instrução de sistema define uma estrutura editorial em três parágrafos com funções distintas. O primeiro parágrafo apresenta o fato central - qual probabilidade mudou, em qual direção, por quanto e com qual intensidade estatística -, com o tema do contrato integrado como oração subordinada em português. O segundo parágrafo contextualiza o que o contrato mede, o que o movimento sugere sobre o cenário econômico e o volume negociado, com resultado final quando disponível. O terceiro parágrafo discute o impacto para o Brasil por meio de canal de transmissão específico - câmbio, custo de crédito doméstico, decisão do Copom, Ibovespa ou, para contratos cripto, exchanges nacionais e instrumentos de investimento listados no Brasil. Em todos os casos, a saída do modelo é texto livre em linguagem natural, sem campos estruturados ou marcação rígida de formato além das tags HTML mínimas exigidas para renderização no dashboard. A instrução de sistema inclui regras negativas explícitas com exemplos dos padrões a evitar - em particular, a citação do título do contrato entre aspas em vez de sua integração como oração subordinada, e o uso do termo "z-score" sem contextualização. Ao final do prompt do usuário, uma instrução de auto-revisão orienta o modelo a verificar se alguma frase do terceiro parágrafo atribui causalidade sem marcador condicional - mecanismo de mitigação do fenômeno de causal hallucination documentado por Ji et al. [17]. O user prompt fornece a variação calculada como diferença direta entre prob_yes e prob_antes, com a fórmula numérica explicitada, para eliminar inconsistências entre os valores exibidos e a variação declarada.

3.5.3 Cascata de modelos e fallback automático

A geração de cada narrativa é tentada sequencialmente por uma cascata de quatro modelos de linguagem: Gemini 2.5 Flash (Google AI), Llama 3.3 70B via Groq, Gemma 3 12B via OpenRouter e Qwen 2.5 72B via OpenRouter. A ordem da cascata foi de-

finida durante o desenvolvimento do artefato, considerando disponibilidade operacional, estabilidade das respostas e desempenho observado nas execuções de teste. O Gemini 2.5 Flash é posicionado como modelo primário, recorrendo-se aos modelos subsequentes apenas quando o anterior retorna erro, resposta vazia ou geração interrompida por filtro de segurança. A mesma instrução de sistema e o mesmo conjunto de dados estruturados são fornecidos a todos os modelos, garantindo comparabilidade das narrativas independentemente do modelo ativado. O campo `modelo_usado` no payload de saída registra qual modelo gerou cada narrativa, constituindo evidência empírica da distribuição de uso da cascata.

3.6 Avaliação do artefato

3.6.1 Brier Score

A acurácia preditiva dos dados consumidos pelo sistema é avaliada pelo Brier Score (BS), métrica padrão para previsões probabilísticas binárias, conforme proposto por 21 e calculada pela Equação 3.6.

$$BS = \frac{1}{N} \sum_{t=1}^N (p_t - o_t)^2 \quad (3.6)$$

Em que BS representa o Brier Score do conjunto de previsões avaliadas, N corresponde ao número total de contratos com desfecho conhecido utilizados na avaliação, p_t representa a probabilidade implícita de mercado observada no instante em que o sinal foi detectado para o contrato t , e $o_t \in \{0, 1\}$ representa o desfecho efetivamente observado desse contrato, assumindo valor 1 quando o evento ocorreu e 0 caso contrário.

Valores menores de BS indicam maior acurácia preditiva, sendo $BS = 0$ o valor correspondente à previsão perfeita. Como referência, considera-se o baseline $BS = 0,25$, obtido por um preditor não informativo que atribui probabilidade constante de 50% a todos os eventos.

O BS é calculado sobre o subconjunto de 37 contratos com desfecho conhecido, utilizando como previsão a probabilidade observada no momento do sinal, e não a probabilidade final do contrato. Essa escolha é metodologicamente coerente com o propósito do sistema, que consiste em avaliar o valor informacional do sinal no instante em que ele é detectado, e não após a convergência do mercado para o resultado observado.

Embora o objetivo principal do trabalho não seja produzir previsões, essa métrica permite verificar se os sinais consumidos pelo sistema provêm de mercados com capacidade preditiva consistente.

3.6.2 Análise de sensibilidade do limiar z^*

A robustez do limiar de detecção z^* , que representa o valor mínimo do z-score contextual necessário para que uma observação seja considerada um sinal candidato, é avaliada utilizando três configurações (1,5, 2,0 e 2,5) sobre o corpus completo. Para cada configuração, são calculados o número de sinais brutos detectados, o número de sinais após deduplicação e a razão de cobertura líquida — métrica proposta no presente trabalho, definida como a proporção de sinais deduplicados correspondentes a contratos com volume superior a US\$ 1 milhão. Essa razão opera como proxy de qualidade porque contratos de alto volume atraem participantes institucionais e são menos suscetíveis a ruído de baixa liquidez.

3.6.3 Avaliação qualitativa das narrativas

Considerando a ausência de métricas automatizadas consolidadas para narrativas macroeconômicas em português, foi desenvolvida uma rubrica de quatro dimensões, baseada em critérios observáveis de fidelidade factual, integração contextual, pertinência econômica e controle de causalidade, adaptados às especificidades do presente sistema. A avaliação foi realizada manualmente pelo autor, mediante aplicação sistemática da rubrica sobre todas as narrativas geradas. Em cada dimensão foi atribuída uma única pontuação inteira (0, 1, 2 ou 3), correspondente ao nível mais alto cujos critérios fossem integralmente atendidos pela narrativa, não sendo utilizadas pontuações intermediárias. A pontuação final corresponde à soma das pontuações obtidas nas quatro dimensões, variando de 0 a 12. As narrativas foram avaliadas individualmente e de forma independente, seguindo os critérios definidos na Tabela 3.

Para reduzir a subjetividade inerente à avaliação manual, cada dimensão foi operacionalizada por critérios observáveis, definidos de forma a reduzir a sobreposição entre os níveis de pontuação. A rubrica é composta por quatro dimensões complementares: (i) ancoragem factual, (ii) integração do tema, (iii) pertinência do canal Brasil e (iv) controle

de causalidade. Os critérios de pontuação adotados para cada dimensão são apresentados na Tabela 3.

Tabela 3: Rubrica de avaliação qualitativa das narrativas geradas pelo Signal.

Dimensão	0	1	2	3
D1: Ancoragem Factual	A narrativa não cita os números do evento ou apresenta valores incorretos.	A probabilidade inicial está correta, mas a variação em pontos percentuais não aparece ou está incorreta.	A probabilidade inicial e a variação em pontos percentuais estão corretas. O z-score é mencionado apenas de forma descritiva.	Todos os dados quantitativos relevantes aparecem corretamente e de forma organizada, incluindo probabilidade inicial, probabilidade no momento do sinal, variação em pontos percentuais e, quando pertinente, a intensidade estatística do evento.
D2: Integração do Tema	O título do contrato é reproduzido literalmente, em inglês ou entre aspas, sem integração ao texto.	O tema foi traduzido, mas ainda apresenta jargões próprios do contrato ou do mercado financeiro.	O tema é integrado naturalmente ao texto em português, sem aspas nem jargões técnicos.	Além da integração natural, a narrativa contextualiza o contrato no evento macroeconômico correspondente, relacionando-o ao resultado conhecido ou aos demais contratos do mesmo evento.
D3: Pertinência do Canal Brasil	Não há menção a impactos para o Brasil ou a afirmação é excessivamente genérica.	Um canal de transmissão é citado (por exemplo, câmbio, Copom ou Ibovespa), mas sem justificar sua relação com o evento.	O canal de transmissão é relacionado corretamente à direção do sinal, explicando por que seria afetado.	Além da justificativa, a narrativa identifica explicitamente um instrumento, instituição, mercado ou empresa brasileira relevante para o evento.
D4: Controle de Causalidade	A narrativa inventa uma causa não sustentada pelos dados disponíveis.	A narrativa apresenta uma causa plausível, porém não sustentada pelos dados, tratando-a como fato.	A narrativa utiliza linguagem condicional (por exemplo, "pode indicar", "sugere" ou "possivelmente"), deixando claro tratar-se de hipótese.	A narrativa limita as relações causais aos fatos sustentados pelos dados do contrato, mencionando apenas informações verificáveis.

3.6.4 Procedimento Experimental

A execução do sistema segue um procedimento experimental fixo, repetido a cada ciclo de coleta e avaliação:

1. Coleta dos contratos: Aquisição dos metadados via Gamma API e do histórico de preços via CLOB API, com aplicação dos critérios de inclusão descritos na Seção 3.3;
2. Cálculo do detector: Aplicação do z-score contextual sobre as séries coletadas, seguida da deduplicação por impacto ponderado, conforme as Seções 3.4.2 a 3.4.4;

3. Geração das narrativas: Submissão dos sinais selecionados à cascata de modelos de linguagem, com persistência do resultado e do registro de fallback em `demo_cache.json`;
4. Avaliação quantitativa: Cálculo do Brier Score sobre o subconjunto de contratos com desfecho conhecido e execução da análise de sensibilidade do limiar z^* sobre o corpus completo;

Esse procedimento é executado de forma idempotente: a reexecução do pipeline sobre o mesmo corpus não duplica sinais já processados, em razão do mecanismo de persistência descrito na Seção 3.2.

3.7 Limitações Metodológicas

Quanto à representatividade do corpus, os 51 contratos avaliados concentram-se em FOMC e Cripto, o que limita a generalização dos resultados para outros domínios de mercados preditivos: inflação, desemprego e eventos geopolíticos. A expansão do escopo foi planejada no design do sistema, mas a ausência de contratos com volume e histórico suficientes nas demais categorias da Polymarket no período avaliado impediu a coleta. Outra limitação decorre da avaliação qualitativa ter sido conduzida por um único avaliador, o próprio autor, sem verificação de concordância inter-avaliadores. Esse é um ponto de aprimoramento metodológico natural para trabalhos futuros, com a participação de avaliadores independentes com perfis distintos: jornalistas econômicos, economistas e leitores não especializados. Também deve ser considerado que o Brier Score é calculado usando a probabilidade no momento do sinal detectado, não a probabilidade final do contrato. Essa escolha é coerente com o propósito do sistema, mas implica que o BS não reflete a acurácia máxima que os contratos da Polymarket podem oferecer, apenas a acurácia do ponto específico de entrada capturado pelo detector. A dependência de uma única fonte de dados, a Polymarket, constitui outra limitação relevante. Os resultados não podem ser diretamente generalizados para outras plataformas, como a Kalshi, que opera sob regime regulatório distinto e pode apresentar dinâmica de formação de preço diferente. Por fim, a dependência de modelos de linguagem de terceiros introduz dois tipos de limitação: heterogeneidade de qualidade entre os modelos da cascata, com variações estilísticas e de ancoragem factual documentadas empiricamente na comparação entre lotes da Seção 4; e instabilidade potencial decorrente de mudanças nas APIs e políticas

de uso dos provedores, que podem afetar a reprodutibilidade do sistema em execuções futuras.

A Tabela 4 apresenta a notação adotada ao longo das formulações do detector. Os símbolos definidos são utilizados para formalizar as métricas e variáveis empregadas nas etapas de detecção de eventos, priorização e avaliação dos sinais gerados pelo sistema.

Tabela 4: Notação utilizada nas formulações do detector.

Símbolo	Descrição
$P(t)$	Probabilidade do contrato no instante t
$\Delta P(t)$	Varição diária da probabilidade
$z(t)$	z-score contextual
$\hat{\sigma}(t)$	Desvio-padrão local das variações
z^*	Limiar de detecção de anomalias
$\text{Impacto}(t)$	Métrica de priorização utilizada na deduplicação dos sinais
BS	Brier Score
N	Número de contratos avaliados
p_t	Probabilidade implícita do mercado no instante do sinal
o_t	Desfecho observado do contrato

4 RESULTADOS

Esta seção apresenta os resultados obtidos na avaliação do sistema Signal. Inicialmente são apresentados os resultados da análise de sensibilidade do detector de eventos, seguida da avaliação da qualidade preditiva dos sinais por meio do Brier Score. Em seguida, são apresentados os resultados da avaliação qualitativa das narrativas produzidas pelo sistema, realizada em duas etapas sucessivas do desenvolvimento do artefato. Por fim, são discutidos os falsos positivos identificados durante a construção do corpus.

4.1 Análise de sensibilidade do limiar de detecção

A análise de sensibilidade foi conduzida sobre o conjunto completo de mercados coletados, aplicando o detector com três valores distintos para o limiar de detecção (z^*): 1,5; 2,0 e 2,5. Para cada valor foram registrados o número de sinais brutos detectados, o número de sinais preservados após a deduplicação por impacto, a distribuição dos eventos segundo a magnitude do z-score e a razão de cobertura líquida, definida como a proporção de sinais deduplicados associados a contratos com volume negociado superior a US\$ 1 milhão. Os resultados são apresentados na Tabela 4. A diferença entre o número de sinais deduplicados reportado nesta análise e o total de narrativas avaliadas decorre da própria lógica operacional do pipeline. A deduplicação é executada antes da etapa de iteração sobre os eventos para geração textual; portanto, os 204 sinais deduplicados observados no parâmetro padrão $z^* = 2,0$ representam o conjunto de eventos candidatos produzido pelo detector, e não o total de narrativas efetivamente geradas. Como a geração por modelos de linguagem envolve custo computacional e uso de APIs externas, a etapa de geração narrativa foi limitada a um subconjunto de 51 eventos, posteriormente submetido à avaliação qualitativa. Essa delimitação preserva a validade da análise de sensibilidade do detector, mas restringe o escopo empírico da avaliação textual ao corpus final de narrativas processadas.

Tabela 5: Análise de sensibilidade do limiar z^* sobre o corpus de mercados coletados.

z^*	Sinais brutos	Sinais dedup.	Moderados	Significativos	Fortes/Raros	Cobertura líquida
1,5	3.487	205	3	20	182	0,95
2,0	2.668	204	22	182	0	0,95
2,5	1.854	201	188	13	0	0,95

O primeiro resultado relevante é a estabilidade da razão de cobertura líquida em

0,95 nos três limiares avaliados. Isso indica que, independentemente do ponto de corte escolhido, 95% dos sinais detectados e deduplicados correspondem a contratos com volume superior a US\$ 1,0 milhão, proxy adotado para liquidez suficiente de consenso de mercado. A invariância dessa razão em relação ao limiar é evidência de robustez do detector: o mecanismo de deduplicação por impacto ($|z| \cdot \log(\text{volume})$) filtra eficazmente os sinais de baixa liquidez em todos os cenários testados.

O segundo resultado relevante é a estabilidade do número de sinais deduplicados: 205, 204 e 201 para $z^* = 1,5$, 2,0 e 2,5, respectivamente. Embora o número de sinais brutos varie substancialmente (3.487 contra 1.854), a deduplicação converge para um conjunto semelhante de eventos únicos em todos os cenários, o que demonstra que os sinais brutos adicionais capturados por limiares mais permissivos não representam eventos genuinamente distintos, mas variações e sub-sinais do mesmo conjunto de eventos relevantes.

A diferença mais informativa entre os limiares manifesta-se na distribuição de magnitude. Com $z^* = 1,5$, 182 dos 205 sinais deduplicados são classificados como Fortes ou Raros, o que indica que o limiar mais permissivo captura principalmente eventos de alta intensidade relativa, resultado contraintuitivo que decorre do mecanismo de deduplicação por impacto: ao selecionar o sinal de maior $|z|$ dentro de cada janela temporal, a deduplicação tende a privilegiar os picos de intensidade.

Com $z^* = 2,0$, todos os 204 sinais concentram-se nas categorias Moderado (22) e Significativo (182), refletindo o comportamento dos sinais preservados após a deduplicação, sem que isso possa ser atribuído exclusivamente aos contratos FOMC, já que o corpus final contém maior número de eventos cripto do que FOMC. A mudança na distribuição de magnitude entre os limiares deve ser interpretada com cautela, pois a classificação final resulta da interação entre o limiar de detecção e o módulo de deduplicação por impacto ponderado.

Assim, os resultados não indicam apenas a sensibilidade do z-score, mas também o efeito seletivo da etapa de deduplicação sobre os sinais preservados. Com base nesses resultados, o valor $z^* = 2,0$ foi adotado como parâmetro padrão do sistema por oferecer a distribuição de magnitude mais equilibrada e semanticamente coerente com o objetivo de detecção de variações genuinamente anômalas.

4.2 Acurácia Preditiva: Brier Score

Para o cálculo do Brier Score, foram considerados apenas os 37 eventos com desfecho conhecido. A probabilidade utilizada correspondeu à probabilidade observada no momento do sinal detectado, antes de qualquer informação posterior ao evento. Eventos ainda em aberto foram excluídos do cálculo, e os falsos positivos foram mantidos na amostra por representarem sinais efetivamente consumidos pelo sistema no momento da execução. O resultado obtido foi $BS = 0,142$, correspondente a uma redução de 43,2% em relação ao baseline não-informativo de $BS = 0,250$ (previsão de 50% de probabilidade para todos os eventos). Para contextualizar esse resultado, é útil comparar com os benchmarks disponíveis na literatura. Diercks, Katz e Wright reportam que os contratos FOMC da Kalshi apresentaram, no período de 2022 a 2025, Brier Score médio em torno de 0,10 para previsões realizadas às vésperas das reuniões, quando a incerteza já se reduziu substancialmente [3]. O BS de 0,142 obtido no presente trabalho é calculado sobre o momento do sinal, que ocorre em média semanas antes do desfecho, quando a incerteza é maior. A comparação direta não é metodologicamente adequada, mas o resultado confirma que o sistema consome dados com poder preditivo real, consistente com a literatura. A distribuição do erro por categoria revela que os eventos FOMC com desfecho conhecido apresentam Brier Score inferior ao dos eventos Cripto. No corpus avaliado, há 17 eventos FOMC e 20 eventos Cripto com resultado conhecido, o que é coerente com a maior homogeneidade informacional dos contratos de política monetária, nos quais as decisões do Fed são amplamente antecipadas pelo mercado, em comparação com contratos sobre preços de ativos voláteis, sujeitos a maior imprevisibilidade estrutural. Essa heterogeneidade no desempenho por categoria é documentada como ponto de partida para análises futuras com corpus expandido.

4.3 Avaliação qualitativa das narrativas

4.3.1 Resultados por lote e dimensão

A avaliação qualitativa foi conduzida sobre as 51 narrativas que compõem o corpus final do sistema. A pontuação média geral obtida foi de 9,69/12 (desvio-padrão de 1,26), com pontuações variando entre 7 e 12 pontos. Ao todo, foram identificados 10 falsos positivos (19,6%), cuja qualidade textual permaneceu elevada, indicando que erros de

detecção não implicam necessariamente degradação da narrativa produzida.

Para analisar a evolução do artefato ao longo do processo de Design Science Research, os resultados foram organizados em dois lotes de avaliação. O Lote 1 corresponde às 32 narrativas produzidas durante a primeira etapa de desenvolvimento do backend, enquanto o Lote 2 reúne 19 narrativas geradas após os refinamentos implementados na versão seguinte do sistema. Como o segundo lote possui menor número de eventos, a comparação entre as etapas concentra-se na distribuição das pontuações e no comportamento das dimensões avaliadas, e não apenas na diferença entre médias gerais. A Tabela Tabela 6 apresenta os resultados consolidados por dimensão.

Tabela 6: Resultados da avaliação qualitativa por dimensão e lote

Métrica	Lote 1 (n=32)	Lote 2 (n=19)
D1: Ancoragem factual	2,31	2,42
D2: Integração do tema	2,81	2,79
D3: Canal Brasil	2,66	2,42
D4: Causalidade controlada	1,97	1,95
Pontuação final média	9,75	9,58
Pontuação mínima	7	7
Pontuação máxima	11	12

Embora a pontuação média global dos dois lotes permaneça muito próxima, observa-se manutenção de desempenho elevado na segunda etapa, com o registro de narrativas que alcançaram a pontuação máxima da rubrica, ausentes no primeiro lote. Esse resultado não deve ser interpretado como melhora média linear entre versões, já que o Lote 2 apresentou média ligeiramente inferior à do Lote 1; ele indica, de forma mais cautelosa, que os refinamentos permitiram a ocorrência de casos plenamente aderentes aos critérios da rubrica.

Esse comportamento é compatível com a natureza incremental do processo de Design Science Research, no qual sucessivos refinamentos tendem a ampliar a qualidade do artefato sem necessariamente produzir aumentos expressivos nas médias globais de desempenho.

4.3.2 Análise por dimensão

4.3.2.1 D1: Ancoragem Factual

A dimensão de Ancoragem Factual apresentou desempenho elevado em ambas as etapas de avaliação, passando de 2,31 para 2,42, o que representa um incremento de 0,11 ponto. Esse resultado indica que as narrativas passaram a reproduzir com maior consistência os valores quantitativos extraídos do pipeline, especialmente probabilidades e variações em pontos percentuais. A proximidade da pontuação máxima demonstra que a maior parte dos textos preservou corretamente as informações estruturadas do evento, restando apenas casos pontuais em que nem todos os elementos quantitativos previstos pela rubrica foram apresentados simultaneamente.

4.3.2.2 D2: Integração do Tema

A dimensão de Integração do Tema manteve desempenho bastante semelhante entre os dois lotes, com média de 2,81 no primeiro e 2,79 no segundo. A diferença observada é pequena e não caracteriza perda relevante de qualidade, indicando estabilidade na capacidade do sistema de transformar títulos de contratos em narrativas naturais em português.

Nas duas etapas, praticamente todas as narrativas conseguiram incorporar o tema ao texto sem reproduzir literalmente o título do contrato. As pequenas variações decorreram principalmente da presença de contextualizações mais completas, enquanto em outros casos a descrição permaneceu mais objetiva, sem prejuízo da compreensão do evento.

4.3.2.3 D3: Pertinência do Canal Brasil

A dimensão referente ao Canal Brasil apresentou médias de 2,66 no primeiro lote e 2,42 no segundo. Embora tenha ocorrido uma pequena redução, ambas permanecem próximas do nível máximo da rubrica, indicando que a maior parte das narrativas conseguiu estabelecer relações plausíveis entre o evento internacional e possíveis impactos sobre a economia brasileira.

As diferenças observadas decorrem principalmente da diversidade dos eventos presentes em cada lote. Alguns contratos do segundo conjunto apresentavam natureza mais

específica, dificultando a identificação de canais nacionais suficientemente particulares para alcançar a pontuação máxima da rubrica. Ainda assim, praticamente todas as narrativas mantiveram conexões coerentes com variáveis como câmbio, política monetária, mercado financeiro ou empresas brasileiras relacionadas ao tema.

4.3.2.4 D4: Controle de Causalidade

A dimensão de Controle de Causalidade manteve desempenho estável nas duas etapas, evidenciando que o sistema evitou atribuir relações causais não sustentadas pelos dados observados. A maior parte das narrativas utilizou linguagem compatível com o caráter probabilístico dos mercados preditivos, recorrendo a expressões condicionais quando interpretava possíveis significados do movimento detectado.

Os poucos casos que não alcançaram a pontuação máxima decorreram da utilização de construções interpretativas mais fortes, ainda que formalmente condicionais, como “pode indicar” ou “sugere que o mercado está precificando”. Embora aceitáveis do ponto de vista da redação financeira, essas formulações foram classificadas de forma mais conservadora pela rubrica.

4.3.3 Exemplos representativos

Entre as narrativas avaliadas, destaca-se o evento identificado pelo ID `bebac9cc5095`, referente ao contrato sobre a possibilidade de o Federal Reserve realizar um corte de 25 pontos-base na reunião de junho de 2026. Esse evento obteve pontuação máxima na rubrica qualitativa, com resultado de 12/12.

Para tornar a análise mais transparente, o Quadro Tabela 7 apresenta a narrativa gerada pelo sistema para esse caso.

Tabela 7: Resumo do evento analisado

Elemento	Descrição
ID do evento	bebac9cc5095
Categoria	FOMC
Contrato analisado	O Fed vai cortar os juros em 25 pontos-base na reunião de junho de 2026?
Variação observada	Queda de 27,5% para 9,5%, equivalente a -14,0 pontos percentuais
Pontuação na rubrica	12/12

Narrativa gerada:

“A probabilidade de o Fed cortar os juros em 25 pontos-base na reunião de junho de 2026 caiu 14,0 pontos percentuais, passando de 27,5% para 9,5%. Essa variação é cerca de 4 vezes fora do padrão histórico deste contrato, indicando uma mudança significativa na percepção dos investidores sobre as decisões futuras do Fed. A redução abrupta na probabilidade sugere que os investidores estão revisitando suas expectativas em relação à política monetária do Fed.

Esse contrato mede a probabilidade de uma redução nos juros pelo Fed, o que pode indicar uma mudança na direção da política monetária. A queda na probabilidade de um corte de juros pode sugerir que os investidores estão prevendo uma manutenção ou até um aumento das taxas de juros, o que pode ter implicações para a economia global. Com um volume total negociado de US\$ 9.433.059, esse movimento reflete a opinião coletiva dos participantes do mercado. No entanto, como o resultado final ainda está em aberto, é preciso aguardar para verificar se a expectativa precificada pelo mercado se confirmará.

A redução na probabilidade de um corte de juros pelo Fed pode ter implicações para o custo do crédito no Brasil, possivelmente aumentando os juros para financiamentos e hipotecas. Além disso, pode influenciar as decisões do Copom, que pode manter ou ajustar as taxas de juros no país. Com o mercado brasileiro atento às decisões do Fed, essas mudanças podem afetar a bolsa e as exportadoras, impactando a economia nacional.”

O exemplo evidencia a aderência da narrativa aos quatro critérios definidos na rubrica de avaliação. Em relação à ancoragem factual, o texto reproduz corretamente a queda da probabilidade de 27,5% para 9,5%, equivalente a uma redução de 14,0 pontos percentuais, além de informar a intensidade estatística do movimento em relação ao padrão histórico do contrato.

Quanto à integração do tema, o contrato é apresentado de forma natural no contexto da política monetária norte-americana, sem mera reprodução literal do título original.

A dimensão referente ao impacto para o Brasil também é contemplada, uma vez que o texto relaciona o evento a possíveis efeitos sobre crédito, política monetária e mercado financeiro brasileiro.

Por fim, a narrativa mantém controle adequado de causalidade ao utilizar formulações condicionais, preservando a natureza probabilística do fenômeno analisado.

No extremo inferior da distribuição, as menores pontuações estiveram associadas a limitações específicas de ancoragem factual, integração contextual ou seleção do sinal. Em alguns casos, esses problemas coincidiram com eventos posteriormente classificados como falsos positivos, indicando que a qualidade da narrativa e a relevância informacional do sinal devem ser avaliadas como dimensões relacionadas, mas distintas. Essa distinção é importante porque uma narrativa pode estar bem escrita e aderente aos dados recebidos, ainda que o sinal estatístico que a originou tenha baixa relevância econômica.

4.4 Falsos positivos

A análise identificou 10 falsos positivos entre os 51 eventos do corpus, resultando em uma taxa de 19,6%, valor que permanece dentro da meta estabelecida na metodologia (inferior a 20%). Desses eventos, sete pertencem à categoria Cripto e três à categoria FOMC, indicando que a maior parte do ruído observado concentrou-se nos contratos relacionados a criptomoedas. Nos contratos de criptomoedas, predominam falsos positivos associados à baixa liquidez, oscilações abruptas provocadas por negociações isoladas e reversões rápidas da probabilidade após o pico detectado. Em vários casos, pequenas alterações absolutas produziram grandes variações relativas devido à probabilidade inicial extremamente reduzida, levando o detector a identificar movimentos que posteriormente não se consolidaram como mudanças efetivas no consenso do mercado. Já nos contratos do FOMC, os falsos positivos concentraram-se em movimentos de pequena magnitude em mercados altamente líquidos. Embora esses sinais tenham ultrapassado os critérios automáticos de detecção, sua persistência temporal mostrou-se limitada, sugerindo flutuações transitórias decorrentes do fluxo normal de negociações e não da incorporação de novas informações econômicas relevantes. Esses resultados indicam que versões futuras do sistema poderão reduzir a taxa de falsos positivos mediante a combinação de critérios adicionais, como a exigência de uma probabilidade mínima inicial para detecção, filtros de persistência temporal do sinal e mecanismos complementares para avaliar a estabilidade do movimento ao longo dos dias subsequentes. Tais aprimoramentos tendem a aumentar a razão sinal-ruído do detector sem comprometer significativamente sua capacidade de identificar eventos economicamente relevantes.

Tabela 8: Falsos positivos identificados durante a avaliação qualitativa.

ID	Categoria	Tipo de falso positivo
8dd7946d12f8	Cripto	Ruído estatístico
4f6ee08b115d	Cripto	Ruído estatístico
2e28571ccbb9	Cripto	Reversão imediata
eef13dcb3008	Cripto	Reversão imediata
e151ebb3034a	Cripto	Reversão imediata
cd14212d4d92	FOMC	Reversão imediata
12d5fd98c65a	FOMC	Reversão imediata
d5e8866502ab	Cripto	Reversão imediata
ac305a78d3b4	Cripto	Reversão imediata
0ee49084ba18	FOMC	Reversão imediata

4.5 Síntese dos resultados

A Tabela 8 sintetiza os principais resultados quantitativos obtidos, comparando os valores alcançados com as metas estabelecidas na metodologia.

Tabela 9: Síntese dos resultados obtidos na avaliação do sistema.

Métrica	Resultado	Meta
Brier score	0,142	$< 0,250$
Pontuação média	9,69	≥ 8
Pontuação máxima	12	12
Falsos positivos	19,6%	$< 20\%$

As diferenças observadas entre as médias das dimensões foram pequenas e devem ser interpretadas considerando que os dois lotes correspondem a conjuntos distintos de eventos. Apesar disso, a segunda etapa passou a registrar narrativas com pontuação máxima prevista pela rubrica (12 pontos), ausentes na primeira etapa de avaliação, evidenciando que os refinamentos implementados ampliaram a capacidade do sistema de produzir narrativas que atendem integralmente aos critérios da rubrica. A avaliação em duas etapas documenta o processo iterativo característico da abordagem de Design Science Research. Em vez de representar uma comparação experimental entre versões, os dois lotes registram a evolução do artefato ao longo do seu desenvolvimento, preservando o mesmo protocolo de avaliação e permitindo observar qualitativamente os efeitos dos refinamentos implementados no backend e nos prompts de geração. Em conjunto, os resultados indicam que o Signal atingiu os objetivos propostos para o artefato desenvolvido. O sistema demonstrou capacidade de identificar movimentos relevantes em mercados pre-

ditivos, utilizar informações com qualidade preditiva consistente e produzir narrativas financeiramente coerentes, factualmente corretas e alinhadas aos critérios estabelecidos pela rubrica de avaliação. Esses resultados fornecem evidências de que a arquitetura proposta constitui uma abordagem viável para apoio à interpretação de sinais provenientes de mercados preditivos.

5 CONCLUSÃO

Este trabalho teve como objetivo investigar a viabilidade de transformar sinais estatísticos extraídos de mercados preditivos macroeconômicos em narrativas factualmente ancoradas em língua portuguesa. Para isso, foi desenvolvido o Signal, um protótipo experimental de inteligência macroeconômica capaz de coletar dados da Polymarket, identificar variações relevantes em séries de probabilidade e convertê-las em explicações textuais por meio de modelos de linguagem de grande porte. A proposta partiu da percepção de que mercados preditivos podem oferecer sinais relevantes sobre expectativas econômicas e financeiras, mas que esses sinais nem sempre são imediatamente compreensíveis para usuários fora de contextos especializados. Uma probabilidade isolada informa uma expectativa de mercado, mas não explica, por si só, se uma mudança foi incomum, se possui relevância informacional ou quais impactos econômicos podem estar associados ao movimento. Nesse contexto, o Signal foi concebido como uma solução experimental para aproximar dados probabilísticos de interpretações macroeconômicas mais claras, contextualizadas e rastreáveis. Os resultados obtidos indicam que essa conversão é viável em nível experimental. A avaliação qualitativa das 51 narrativas geradas apresentou pontuação média de 9,69 em uma escala de 0 a 12, com pontuações variando entre 7 e 12 pontos. Esse desempenho superou as metas definidas na metodologia e demonstra que o sistema foi capaz de produzir narrativas com bom nível de ancoragem factual, integração temática, pertinência econômica e controle de causalidade. Outro resultado positivo foi observado na avaliação da qualidade informacional dos dados consumidos pelo sistema. O Brier Score obtido foi de 0,142, valor inferior ao baseline não informativo de 0,250, indicando que as probabilidades utilizadas apresentaram desempenho superior a uma previsão constante de 50%. Embora o Signal não tenha sido desenvolvido como um sistema preditivo autônomo, esse resultado reforça que os mercados analisados forneceram sinais com conteúdo informacional relevante para a construção das narrativas. A análise de sensibilidade também contribuiu para sustentar a robustez do detector. A razão de cobertura líquida permaneceu estável em 0,95 nos três limiares avaliados, sugerindo que o processo de deduplicação por impacto ponderado foi capaz de preservar sinais associados a contratos com maior volume e, portanto, com menor exposição a ruídos de baixa liquidez. Esse resultado reforça a adequação do limiar padrão adotado e mostra que o detector

apresentou comportamento estável diante de diferentes configurações. Um dos principais aprendizados do trabalho está na importância de separar a detecção estatística da geração textual. No Signal, o modelo de linguagem não decide autonomamente quando há um evento relevante. Essa decisão é tomada previamente pelo detector, que fornece ao modelo informações estruturadas, como direção do movimento, variação em pontos percentuais e intensidade estatística. Essa arquitetura contribuiu para preservar a rastreabilidade das narrativas e reduzir o risco de afirmações não sustentadas pelos dados. A avaliação dos falsos positivos também trouxe um resultado metodologicamente relevante. A taxa observada foi de 19,6%, permanecendo dentro da meta estabelecida no trabalho, embora próxima ao limite definido. Esse achado mostra que o sistema conseguiu operar dentro do critério de aceitabilidade proposto, mas também indica que a etapa de detecção ainda pode ser aprimorada. A distinção entre qualidade da narrativa e qualidade do sinal detectado mostrou-se especialmente importante: uma narrativa pode estar bem escrita e fiel aos dados recebidos, ainda que o evento estatístico que a originou tenha baixa relevância econômica. Como contribuição principal, este trabalho apresenta uma arquitetura integrada que combina mercados preditivos, detecção estatística e geração de linguagem natural em um fluxo único de inteligência macroeconômica. Essa integração permite transformar séries de probabilidade em explicações mais acessíveis ao público brasileiro, preservando a ligação entre o dado numérico e a narrativa final. Além disso, a rubrica qualitativa desenvolvida oferece um instrumento de avaliação voltado a narrativas financeiras em português, considerando não apenas clareza textual, mas também fidelidade factual, contextualização econômica e cautela interpretativa. Os resultados alcançados indicam que o Signal pode servir como base para estudos futuros. Uma primeira possibilidade consiste em ampliar o corpus para outras categorias de mercados preditivos, como inflação, desemprego, crescimento econômico, eventos geopolíticos e decisões de política fiscal. Essa expansão permitiria avaliar se o desempenho observado em contratos FOMC e Cripto se mantém em domínios com diferentes níveis de liquidez, volatilidade e complexidade interpretativa. Outra linha de pesquisa futura envolve a comparação entre diferentes plataformas de mercados preditivos. A inclusão de dados de ambientes regulados, como a Kalshi, permitiria investigar se a dinâmica de formação de preços, volume negociado e qualidade informacional difere de plataformas como a Polymarket. Esse tipo de comparação poderia fortalecer a compreensão sobre em quais condições os

mercados preditivos oferecem sinais mais confiáveis para aplicações de inteligência macroeconômica. Também seria relevante aprimorar o módulo de detecção estatística. Filtros adicionais, como persistência temporal do sinal, probabilidade mínima inicial, critérios mais refinados de liquidez e análise de reversão após o pico detectado, poderiam reduzir a ocorrência de falsos positivos e aumentar a razão sinal-ruído do sistema. Esses refinamentos são particularmente importantes para contratos de baixa liquidez ou eventos com alta volatilidade, nos quais oscilações pontuais podem ser interpretadas de forma equivocada como mudanças relevantes de expectativa. A avaliação qualitativa das narrativas também pode ser expandida em estudos posteriores. A participação de avaliadores independentes, como economistas, jornalistas financeiros, analistas de mercado e leitores não especializados, permitiria medir a concordância na aplicação da rubrica e avaliar a utilidade prática das narrativas para diferentes perfis de usuário. Essa etapa contribuiria para validar a rubrica proposta e aprofundar a compreensão sobre como narrativas geradas automaticamente são percebidas em contextos reais de uso. Por fim, pesquisas futuras podem explorar diferentes configurações de modelos de linguagem, estratégias de prompt e mecanismos de validação automática. Comparar modelos distintos permitiria avaliar quais arquiteturas apresentam melhor equilíbrio entre fluidez, precisão factual, controle de causalidade e adaptação ao português brasileiro. Também seria possível investigar abordagens híbridas, combinando regras determinísticas, validação automática de dados numéricos e geração textual por LLMs. Conclui-se que o Signal alcançou seu objetivo como protótipo experimental. O sistema demonstrou que é possível transformar sinais de mercados preditivos em narrativas macroeconômicas em português com bom nível de fidelidade factual e contextualização econômica. Sua contribuição não está em substituir a análise humana, mas em mostrar que sinais probabilísticos podem ser traduzidos em explicações mais acessíveis, rastreáveis e úteis para apoiar a interpretação de expectativas de mercado. Com isso, o trabalho abre caminho para novas pesquisas sobre o uso integrado de mercados preditivos, métodos estatísticos e modelos de linguagem na construção de ferramentas de inteligência macroeconômica baseadas em dados. Como forma de favorecer a transparência e a reprodutibilidade da pesquisa, o código-fonte do artefato, sua documentação técnica e todos os resultados experimentais utilizados nesta monografia foram disponibilizados em repositório público, incluindo as narrativas geradas, os registros de avaliação qualitativa, a relação completa dos falsos positivos.

REFERÊNCIAS

- [1] GALTON, F. Vox Populi. *Nature*, v. 75, p. 450–451, 1907.
- [2] SUROWIECKI, J. *The Wisdom of Crowds*. New York: Doubleday, 2004.
- [3] DIERCKS, A.; KATZ, B. D.; WRIGHT, J. H. *Kalshi and the Rise of Macro Markets*. [S.l.], 2026.
- [4] WOLFERS, J.; ZITZEWITZ, E. Prediction Markets. *Journal of Economic Perspectives*, v. 18, n. 2, p. 107–126, 2004.
- [5] HAYEK, F. A. The Use of Knowledge in Society. *American Economic Review*, v. 35, n. 4, p. 519–530, 1945.
- [6] FAMA, E. F. Efficient Capital Markets: A Review of Empirical Work. *Journal of Finance*, v. 25, n. 2, p. 383–417, 1970.
- [7] HANSON, R. Combinatorial Information Market Design. *Information Systems Frontiers*, v. 5, n. 1, p. 107–119, 2003.
- [8] GIANNONE, D.; REICHLIN, L.; SMALL, D. Nowcasting: The Real-Time Informational Content of Macroeconomic Data. *Journal of Monetary Economics*, v. 55, n. 4, p. 665–676, 2008.
- [9] KUTTNER, K. N. Monetary Policy Surprises and Interest Rates: Evidence from the Fed Funds Futures Market. *Journal of Monetary Economics*, v. 47, n. 3, p. 523–544, 2001.
- [10] PIAZZESI, M.; SWANSON, E. T. Futures Prices as Risk-Adjusted Forecasts of Monetary Policy. *Journal of Monetary Economics*, v. 55, n. 4, p. 677–691, 2008.
- [11] CHANDOLA, V.; BANERJEE, A.; KUMAR, V. Anomaly Detection: A Survey. *ACM Computing Surveys*, v. 41, n. 3, p. 15:1–15:58, 2009.
- [12] BLÁZQUEZ-GARCÍA, A. et al. A Review on Outlier/Anomaly Detection in Time Series Data. *ACM Computing Surveys*, v. 54, n. 3, p. 1–33, 2021.

- [13] IGLEWICZ, B.; HOAGLIN, D. *How to Detect and Handle Outliers*. Milwaukee: ASQC Quality Press, 1993.
- [14] MCKEOWN, K. R. Discourse Strategies for Generating Natural-Language Text. *Artificial Intelligence*, v. 27, n. 1, p. 1–41, 1985.
- [15] REITER, E.; DALE, R. *Building Natural Language Generation Systems*. Cambridge: Cambridge University Press, 2000.
- [16] GATT, A.; KRAHMER, E. Survey of the State of the Art in Natural Language Generation. *Journal of Artificial Intelligence Research*, v. 61, p. 65–170, 2018.
- [17] JI, Z. et al. Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, v. 55, n. 12, 2023.
- [18] LIU, P. et al. TS-Agent: Understanding and Reasoning Over Raw Time Series via Iterative Insight Gathering. *arXiv preprint arXiv:2510.07432*, 2025.
- [19] HEVNER, A. R. et al. Design Science in Information Systems Research. *MIS Quarterly*, v. 28, n. 1, p. 75–105, 2004.
- [20] MARCH, S. T.; SMITH, G. F. Design and natural science research on information technology. *Decision Support Systems*, v. 15, n. 4, p. 251–266, 1995.
- [21] BRIER, G. W. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, v. 78, n. 1, p. 1–3, 1950.

APÊNDICE A

Disponibilização e Guia do Artefato

Este apêndice apresenta informações complementares sobre o artefato desenvolvido neste trabalho. São descritos a organização do sistema, a estrutura do pipeline implementado, os recursos disponibilizados publicamente e as orientações para reprodução dos experimentos apresentados nesta pesquisa.

5.1 Disponibilização do projeto

O artefato desenvolvido foi disponibilizado em repositório público, contendo o código-fonte, a documentação técnica e os arquivos utilizados durante a avaliação experimental.

- **Repositório GitHub:** <https://github.com/erickdan1/tcc-central-docs>
- **Interface Web:** <https://signal-frontend-pi.vercel.app/>

O repositório corresponde à versão utilizada nos experimentos descritos neste trabalho.

5.2 Organização do notebook

O backend do sistema foi implementado em um notebook Jupyter dividido em módulos independentes, cada um responsável por uma etapa específica do pipeline de processamento.

1. Configuração do ambiente e instalação das dependências;
2. Coleta dos contratos e históricos de preços da API da Polymarket;
3. Tradução automática dos contratos para língua portuguesa;
4. Detecção de eventos utilizando z-score contextual;
5. Análise de sensibilidade dos limiares de detecção;

6. Geração automática das narrativas utilizando modelos de linguagem;
7. Avaliação qualitativa das narrativas segundo a rubrica proposta;
8. Execução integrada do pipeline completo e exportação dos resultados.

5.3 Interface do sistema

As figuras seguintes apresentam as principais telas da interface desenvolvida.




Figura 2: Tela inicial do sistema.

5.4 Arquivos produzidos

Ao término da execução do notebook são produzidos automaticamente os seguintes artefatos:

- análise de sensibilidade;
- relação de eventos processados;
- arquivo JSON contendo os resultados experimentais.




Figura 3: Gráficos de séries temporais e anomalias.




Figura 4: Métricas utilizadas para calibração do detector.

5.5 Reprodução dos experimentos

Para reproduzir os experimentos apresentados neste trabalho recomenda-se executar as seguintes etapas:

1. Clonar o repositório do projeto;
2. Configurar as chaves de acesso às APIs utilizadas;
3. Instalar as dependências descritas na documentação;
4. Executar o notebook sequencialmente;
5. Comparar os resultados obtidos com aqueles apresentados nesta monografia.